

Planification Hospitalière au Prisme de l'IA de Confiance : NSP

Projet Fil Rouge du Mastère Spécialisé® *Intelligence Artificielle de Confiance*

CentraleSupélec, Université Paris-Saclay

Pietro Marco GALLO

1. Introduction

1.1 L'IA de confiance comme cadre régulateur de l'aide à la décision en santé

Le déploiement de systèmes d'IA dans un contexte critique comme la santé soulève des questions qui dépassent la seule performance algorithmique. Les *Ethics Guidelines for Trustworthy AI* de la Commission européenne [19] énoncent sept exigences pour qu'un système soit jugé digne de confiance : (1) agence humaine et supervision ; (2) robustesse technique et sécurité ; (3) respect de la vie privée et gouvernance des données ; (4) transparence ; (5) diversité, non-discrimination et équité ; (6) bien-être sociétal et environnemental ; (7) responsabilité. S'inscrivant dans cette démarche, l'*AI Act* [14] en traduit plusieurs en obligations contraignantes pour les systèmes à haut risque — catégorie dont relève la planification des équipes au titre de l'annexe III, point 4b (gestion de la main-d'œuvre), qui vise l'attribution de tâches fondée sur le comportement ou des caractéristiques individuelles.

À partir de ces sept exigences, ce travail retient quatre attributs particulièrement saillants pour la planification hospitalière :

- Le **respect des contraintes critiques** (réglementaires et de sécurité), condition non négociable dont la violation entraîne des conséquences juridiques ou sanitaires directes ;
- L'**équité** de la distribution des charges, à la fois principe éthique d'égalité de traitement et levier opérationnel de prévention du burnout [22, 27] ;
- La **robustesse** face aux perturbations imprévues (absences, pics de demande), garante de la continuité du service dans un environnement intrinsèquement incertain ;
- L'**explicabilité** des décisions, nécessaire pour que les décideurs humains puissent auditer, comprendre et assumer les plannings vis-à-vis de leurs équipes [28, 40].

Ces attributs ne sont pas indépendants et entrent souvent en tension : un système plus contraint sur l'équité peut sacrifier les préférences individuelles, un système plus robuste être moins lisible, un système plus explicable moins performant. C'est précisément l'étude empirique de ces compromis qui constitue l'objet de ce projet fil rouge.

1.2 La planification hospitalière comme cas d’application critique

La planification hospitalière est un terrain d’étude privilégié pour ces quatre attributs. Ses contraintes critiques y sont *tangibles et codifiées* : le Code du Travail français fixe le repos minimum entre créneaux (11 h, art. L3131-1 [34]) et la durée maximale hebdomadaire de travail (48 h, art. L3121-20 [33]), et les exigences médicales imposent une couverture minimale des postes. En outre, l’équité et la robustesse y sont *concrètement mesurables* : la répartition des nuits, des weekends et de la charge globale est quantifiable par des indices normalisés (indice de Jain [20]), et l’impact d’une absence ou d’une épidémie par le coût empirique de sa réparation. L’enjeu, enfin, est de *santé publique* : la dotation en personnel infirmier est corrélée à la mortalité des patients ainsi qu’à l’épuisement et à l’insatisfaction des soignants [2].

Au sein de ce domaine, ce projet retient le *Nurse Scheduling Problem* (NSP), qui consiste à affecter un ensemble d’infirmiers à des créneaux de travail sur un horizon donné. Formalisé dès 1972 [39] et reconnu comme NP-difficile [11], le NSP concentre les difficultés inhérentes à la planification en santé — multiplicité des contraintes, caractère combinatoire, arbitrage entre objectifs concurrents — sans requérir aucune donnée clinique sensible, ce qui en fait un microcosme idéal pour l’étude méthodologique des attributs de confiance.

1.3 Contributions

Ce projet compare trois approches de résolution du NSP, évaluées *systématiquement* sur les quatre attributs de confiance mentionnés dans la Section 1.1 : MILP, recuit simulé et un modèle de ML couplé à un solveur MILP. Les contributions sont triples :

- Une formalisation du NSP *dérivée des attributs de confiance*, où chaque contrainte et chaque pénalité de la fonction objectif est rattachée explicitement à un attribut ;
- Une analyse comparative des trois approches couvrant les quatre attributs, complétée par des scénarios de perturbation ;
- Une étude d’*explicabilité* structurelle du MILP, fondée sur les fronts de Pareto bi-objectifs et l’analyse de saturation des contraintes, puis complétée pour l’approche hybride par une étude SHAP des caractéristiques influentes.

2. État de l’Art

2.1 Cadre normatif et conceptuel de l’IA de confiance

Les sept exigences des *Ethics Guidelines* [19], consolidées par l’*AI Act* [14], fournissent la grille d’évaluation de référence. Leur application à des systèmes d’aide à la décision opérationnels en santé fait ressortir des exigences spécifiques (auditabilité des décisions [28, 40], garantie formelle du respect des contraintes réglementaires, prise en compte du bien-être du personnel), mais ces travaux restent généralement de nature conceptuelle ou qualitative plutôt que de proposer une mise en œuvre.

Du côté du NSP, Burke et al. [5] recensent les grandes familles de méthodes — programmation mathématique, heuristiques constructives, métaheuristiques, systèmes experts — et observent

qu’aucune ne domine sur l’ensemble des instances, la grande diversité des formulations [15] rendant la comparaison directe difficile. Ce constat a motivé les compétitions standardisées INRC-I [17] et INRC-II [7], appuyées sur les jeux de données de référence de Curtois [12]. Van den Bergh et al. [38], en analysant plus de 200 articles, dégagent comme directions futures l’intégration de l’incertitude, la prise en compte des préférences des employés et l’essor des méthodes hybrides.

2.2 Méthodes classiques pour le NSP

Les approches classiques se répartissent en deux familles :

- Les **méthodes exactes** reposent sur la programmation linéaire mixte en nombres entiers (MILP) et des techniques de décomposition avancées, telles que la génération de colonnes et le *branch-and-price* [36, 16, 25]. Lorsqu’elles aboutissent, elles fournissent des garanties d’optimalité pour l’analyse de sensibilité ; leur limite est la scalabilité, les temps de résolution devenant prohibitifs au-delà de quelques dizaines d’infirmiers sur un horizon mensuel [38] ;
- Les **métaheuristiques** — recuit simulé [6], recherche tabou, approches matheuristiques [31, 3] — traitent des grandes instances en temps raisonnable, au prix de l’absence de garantie d’optimalité et de la difficulté à garantir l’admissibilité de la solution finale sans mécanisme de réparation.

2.3 Approches hybrides : apprentissage automatique pour l’optimisation

Coupler apprentissage automatique et optimisation combinatoire est une tendance récente. Le survey méthodologique de Bengio et al. [4], complété pour l’ordonnancement par Ouhadi et al. [30], distingue trois paradigmes d’intégration : l’apprentissage *de bout en bout*, qui prédit directement la solution [24, 1] ; l’apprentissage pour *guider* le solveur, comme la prédiction des décisions de branchement [21] ; et l’apprentissage produisant un *warm-start* raffiné ensuite par un solveur exact [13, 37]. Appliqués au NSP, plusieurs travaux combinent des réseaux de neurones et la programmation mathématique [10, 9] ou recourent à l’apprentissage par renforcement [23].

2.4 Attributs de confiance dans la planification hospitalière

Si le cadre conceptuel de l’IA de confiance fournit une grille cohérente, son application au NSP reste fragmentaire : chaque attribut a été étudié de manière isolée, sans cadre d’évaluation intégré. L’asymétrie sur la garantie d’admissibilité d’une solution, qui encode le **respect des contraintes critiques**, entre les méthodes exactes (sauf infaisabilité) et les métaheuristiques est peu discutée dans les comparaisons classiques, qui se focalisent plutôt sur la seule valeur de l’objectif. Quant à l’**équité**, l’usage d’indices normalisés tels que l’indice de Jain [20] comme pénalité souple y reste marginal. Les **préférences** individuelles ont été traitées par programmation par buts [35] et, plus récemment, par des études d’acceptabilité des plannings par IA [32]. La **robustesse** est abordée de façon soit *proactive*, en intégrant l’incertitude dès la modélisation via des modèles stochastiques ou robustes [18, 41] ; soit *réactive*, en mesurant la capacité d’une solution à être réparée a posteriori après perturbation ; l’intégration de modèles de fatigue [22] et d’épuisement professionnel [27] traduit une sensibilité accrue aux dimensions humaines. L’**explicabilité** des solutions d’optimisation combinatoire est un champ émergent : le MILP dispose nativement d’outils d’interprétation rarement mobilisés de manière systématique,

tandis que des outils du ML explicable comme SHAP [26] permettent d’éclairer l’importance des descripteurs dans la prédiction de solutions initiales.

2.5 Synthèse et positionnement

La littérature met ainsi en évidence une triple opportunité : les surveys récents identifient les méthodes hybrides [29, 30], ainsi que l’incertitude et les préférences [38], comme directions émergentes sans qu’un cadre intégré n’existe à ce jour ; les approches hybrides ML + optimisation, aujourd’hui matures dans d’autres domaines combinatoires, restent peu appliquées au NSP avec une évaluation rigoureuse. Le positionnement de ce projet vise à une évaluation conjointe et systématique des quatre attributs de confiance sur des méthodes concurrentes pour le NSP.

3. Cadre d’Évaluation : Les Quatre Attributs de Confiance

3.1 Respect des contraintes critiques

Un planning hospitalier doit garantir le respect des contraintes réglementaires retenues (cf. Section 4.3) et de sécurité (couverture minimale des postes pour assurer la qualité des soins). Cet attribut relève de l’exigence de *robustesse technique et sécurité* formulée par les Ethics Guidelines [19] et opérationnalisée par les articles 9 et 15 de l’AI Act sur les systèmes à haut risque [14].

La métrique associée est binaire dans son principe : le *taux de satisfaction* de ces contraintes dures, exigé à 100 %. En pratique, on mesure également le nombre absolu de violations résiduelles après résolution, indicateur secondaire utile pour diagnostiquer les algorithmes qui ne garantissent aucune admissibilité par construction, comme les métaheuristiques.

3.2 Équité

L’équité de la distribution de la charge de travail entre infirmiers est un principe à la fois éthique (égalité de traitement entre agents d’un même service) et opérationnel (prévention du burnout, lié à une charge de travail inéquitable [22, 27]). Elle relève de l’exigence de *diversité, non-discrimination et équité* des Ethics Guidelines [19].

L’équité est ici mesurée par l’*indice d’équité de Jain* [20], défini par :

$$\text{JFI}(W_1, \dots, W_N) = \frac{\left(\sum_{n=1}^N W_n\right)^2}{N \cdot \sum_{n=1}^N W_n^2} \in \left[\frac{1}{N}, 1\right], \quad (1)$$

Cet indice, originellement proposé pour l’allocation de ressources dans les systèmes informatiques partagés, varie entre les valeurs $\frac{1}{N}$ en cas d’iniquité maximale (une seule personne porte toute la charge) et 1 en cas d’équité parfaite (toutes les charges sont égales). L’évaluation est conduite sur trois grandeurs : (1) la charge totale sur l’horizon temporel ; (2) le nombre de nuits travaillées ; (3) le nombre de jours de weekend travaillés.

3.3 Robustesse

Un planning hospitalier doit pouvoir absorber des perturbations imprévues sans dégradation catastrophique de sa qualité ou violation des contraintes critiques. Cet attribut relève des exigences de *robustesse technique* des Ethics Guidelines [19] et de la prévention des risques sanitaires, particulièrement saillante depuis la pandémie de COVID-19 [27].

On adopte ici une approche *réactive* de la robustesse, approche dont la littérature souligne la rareté [38] : plutôt que d'intégrer l'incertitude dans le modèle d'optimisation lui-même, on mesure *a posteriori* la capacité d'une solution nominale à être réparée face à une perturbation. Trois scénarios standardisés sont retenus dans le Tableau 1 :

ID	Perturbation
P1	<i>Absence individuelle</i> : un infirmier s'absente un jour aléatoire.
P2	<i>Pic de demande</i> : $\text{Req}(d, s) \rightarrow \text{Req}(d, s) + 1$ sur un créneau durant 3 jours consécutifs.
P3	<i>Épidémie</i> : trois infirmiers simultanément en arrêt maladie pour 2 jours consécutifs.

Table 1: Scénarios de perturbation pour l'évaluation de la robustesse.

Pour chaque scénario, trois métriques quantitatives sont mesurées : (i) le *coût de réparation*, défini comme la distance de Hamming entre la solution nominale et la solution réparée optimalement ; (ii) la *dégradation relative* de la fonction objectif, $\Delta Z = \frac{Z_{\text{rép.}} - Z_{\text{orig.}}}{Z_{\text{orig.}}}$; (iii) le *temps de réparation*, mesuré comme le temps de résolution du solveur. L'absence de violations résiduelles après réparation est en outre vérifiée systématiquement.

3.4 Explicabilité

Un cadre de santé doit pouvoir comprendre et justifier les choix d'affectation produits par le système, afin d'auditer le planning, de l'expliquer aux équipes et d'en assumer la responsabilité. Cet attribut relève de l'exigence de *transparence* des Ethics Guidelines [19] et est particulièrement critique dans le secteur de la santé [28, 40].

L'explicabilité est abordée selon trois axes complémentaires :

- **(E1) Analyse de sensibilité** aux poids α_i de la fonction objectif. Le tracé des fronts de Pareto bi-objectifs permet de cartographier les compromis réalisables et de justifier de manière transparente le choix opérationnel des poids ;
- **(E2) Identification des *contraintes déterminantes*** via la saturation à l'égalité des contraintes primales du problème. L'analyse de saturation fournit une justification qualitative des contraintes qui lient l'affectation. Cette justification structurelle n'est disponible que pour les approches atteignant une borne de suboptimalité certifiée (MILP et, par héritage, l'hybride) : pour le SA, dont les solutions sont des minima locaux, une affectation non préférée ne peut être attribuée de façon univoque à une contrainte active plutôt qu'à la suboptimalité ;
- **(E3) Importance des descripteurs** dans l'approche hybride. Pour le modèle de ML utilisé en warm-start, l'analyse SHAP identifie les caractéristiques des instances (taille, profil de demande, distribution de préférences) qui influencent le plus la prédiction.

Ces trois axes ne sont pas mutuellement exclusifs : ils correspondent à trois niveaux d’analyse (global/structurel/local) compatibles avec les recommandations de la littérature récente [28].

4. Formalisation : Encodage des Attributs de Confiance

Le NSP consiste à affecter N infirmiers à des créneaux de travail sur un horizon de D jours, en respectant des exigences réglementaires, organisationnelles, humaines et de sécurité, tout en optimisant la qualité globale du planning. On y distingue les contraintes **dures**, qui fournissent la garantie *formelle* du respect de ces exigences ; et les contraintes **souples**, intégrées à la fonction objectif, qui permettent de *quantifier* et d’*arbitrer* entre objectifs concurrents.

Attribut de confiance	Encodage dans le modèle
Respect des contraintes critiques	Contraintes dures (H1)–(H6)
Équité	Pénalités souples P_{eq} , P_{we}
Satisfaction du personnel	Pénalité souple P_{pref}
Explicabilité structurelle	Poids α_i et pénalités P_i (objectif)
Robustesse	Protocole de perturbation (hors formulation)

Table 2: Encodage des attributs de confiance dans la formulation du NSP. Seule la robustesse n’est pas encodée dans le modèle : elle est évaluée *a posteriori* par le protocole de perturbation.

4.1 Ensembles, variables et paramètres

Type	Symbole	Description	Valeur
Couverture	$Req(d, s)$	Nombre min. d’infirmiers requis au créneau (d, s)	—
Réglementaire	W_{max}	Jours de travail consécutifs max	5–6
	N_{max}	Nuits par horizon max	3–4
	H_{min}	Repos minimum entre créneaux	8 h
	WE_{min}	Weekends libres min. par infirmier	1–2
Préférence	$pref(n, d, s)$	Préférence absolue de n pour (d, s) , valeur indiquant l’intensité de préférence, générée par une loi Beta($\alpha = 2, \beta = 2$). Valeur de défaut à 0.5 pour $pref(n, d, R)$	$[0, 1]$
	WE_{target}	Nombre cible de <i>jours de weekend</i> travaillés par infirmier : $\frac{1}{N} \sum_{d \in \mathcal{W}} \sum_{s \in \mathcal{S}_{work}} Req(d, s)$	—

Table 3: Paramètres du problème.

Le modèle repose sur l’ensemble des infirmiers $\mathcal{N} = \{1, \dots, N\}$, l’horizon des jours mensuels $\mathcal{D} = \{1, \dots, D\}$, l’ensemble des créneaux $\mathcal{S}_{work} = \{M, A, N\}$ (Matin, Après-midi, Nuit) et l’ensemble étendu $\mathcal{S}' = \mathcal{S}_{work} \cup \{R\}$ incluant le repos. Chaque créneau de $\mathcal{S}_{work}$ dure 8 heures : 7h00–15h00 (M), 15h00–23h00 (A), 23h00–7h00 (N). Le sous-ensemble $\mathcal{W} \subseteq \mathcal{D}$ désigne les jours de weekend dans l’horizon temporel $\mathcal{D}$. La variable de décision principale est binaire :

$$x_{n,d,s} \in \{0, 1\} \quad \forall n \in \mathcal{N}, d \in \mathcal{D}, s \in \mathcal{S}' \quad (2)$$

avec $x_{n,d,s} = 1$ si et seulement si l’infirmier n est affecté au créneau s le jour d , 0 sinon. Pour simplifier la formalisation de quelques contraintes, on introduit la variable auxiliaire $y_{n,d} = \sum_{s \in \mathcal{S}_{\text{work}}} x_{n,d,s}$, qui vaut 1 si n travaille le jour d , 0 sinon¹.

4.2 Dataset

Le projet se fonde sur la construction d’un dataset de 50 instances indépendantes générées en variant le nombre d’infirmiers $N \in \{22, \dots, 28\}$ et la graine de génération des préférences. L’horizon temporel est figé à $D = 28$ jours. La graine contrôle la *diversité du dataset*, et non la réplication statistique. Le dataset est divisé en 40 instances d’entraînement et 10 de test.

4.3 Contraintes dures : encodage du respect des contraintes critiques

- **Unicité d’affectation (H1)** : $\sum_{s \in \mathcal{S}'} x_{n,d,s} = 1 \quad \forall n \in \mathcal{N}, d \in \mathcal{D}$
- **Couverture minimale (H2)** : $\sum_{n \in \mathcal{N}} x_{n,d,s} \geq \text{Req}(d, s) \quad \forall d \in \mathcal{D}, s \in \mathcal{S}_{\text{work}}$
- **Interdiction $N \rightarrow M$ (H3)** : $x_{n,d,N} + x_{n,d+1,M} \leq 1 \quad \forall n \in \mathcal{N}, d \in \mathcal{D} \setminus \{D\}$
- **Jours consécutifs (H4)** : $\sum_{k=d}^{d+W_{\max}} y_{n,k} \leq W_{\max} \quad \forall n \in \mathcal{N}, d \in \{1, \dots, D - W_{\max}\}$
- **Limite de nuits (H5)** : $\sum_{d \in \mathcal{D}} x_{n,d,N} \leq N_{\max} \quad \forall n \in \mathcal{N}$
- **Weekends libres (H6)** : $\text{WE}_{\text{free}}(n) \geq \text{WE}_{\min} \quad \forall n \in \mathcal{N}$

Parmi elles, (H3) encode le repos minimum $H_{\min} = 8$ h induit par la partition 3×8 : le seul enchaînement offrant moins de 8 h de repos est $N \rightarrow M$, interdit par (H3), les cumuls au sein d’un même jour étant exclus par (H1) — une simplification par rapport au repos légal de 11 h, discutée en Section 6.5. Dans (H6), $\text{WE}_{\text{free}}(n)$ désigne le nombre de weekends où l’infirmier $n \in \mathcal{N}$ est en repos samedi *et* dimanche.

4.4 Contraintes souples : encodage de l’équité et de l’acceptabilité

- **Équité de la charge de travail (S1)** : $P_{\text{eq}} = \sum_{n \in \mathcal{N}} |W(n) - \bar{W}|$
- **Équité des weekends (S2)** : $P_{\text{we}} = \sum_{n \in \mathcal{N}} |\text{WE}_{\text{work}}(n) - \text{WE}_{\text{target}}|$
- **Satisfaction des préférences (S3)** : $P_{\text{pref}} = \sum_{n \in \mathcal{N}} \sum_{d \in \mathcal{D}} \sum_{s \in \mathcal{S}_{\text{work}}} (1 - \text{pref}(n, d, s)) x_{n,d,s}$
- **Continuité des créneaux (S4)** : $P_{\text{cont}} = \sum_{n \in \mathcal{N}} \sum_{d=1}^{D-1} c_{n,d}$

Ces contraintes font intervenir ces variables auxiliaires :

- $W(n) = \sum_{d \in \mathcal{D}} y_{n,d}$: charge totale de travail de l’infirmier n ;
- $\bar{W} = \frac{1}{N} \sum_{n' \in \mathcal{N}} W(n')$: charge moyenne ;
- $\text{WE}_{\text{work}}(n) = \sum_{d \in \mathcal{W}} \sum_{s \in \mathcal{S}_{\text{work}}} x_{n,d,s}$: nombre de *jours de weekend* travaillés par n ;
- $c_{n,d} \in \{0, 1\}$: éventuel changement de créneau de l’infirmier n entre les jours d et $d + 1$.

¹La contrainte (H1) assure $y_{n,d} \in \{0, 1\} \quad \forall n \in \mathcal{N}, d \in \mathcal{D}$.

4.5 Fonction objectif : arbitrage explicite entre attributs

$$\begin{aligned} \min \quad & Z = \alpha_{\text{eq}} \cdot P_{\text{eq}} + \alpha_{\text{we}} \cdot P_{\text{we}} + \alpha_{\text{pref}} \cdot P_{\text{pref}} + \alpha_{\text{cont}} \cdot P_{\text{cont}} \\ \text{s.t.} \quad & (\text{H1})\text{--}(\text{H6}), \quad \alpha_{\text{eq}}, \alpha_{\text{we}}, \alpha_{\text{pref}}, \alpha_{\text{cont}} \geq 0 \end{aligned} \quad (3)$$

Le choix de la *somme pondérée* confère aux poids de calibration α_i un double rôle :

- *Rôle mécanique.* Les quatre pénalités P_i sont définies sur des échelles hétérogènes (plages observées de 0–18, 6–8, 70–160 et 35–150). À poids unitaires, la contribution de chaque composante refléterait son amplitude plutôt qu’une priorité ; les α_i rendent cet arbitrage délibéré, sans viser l’égalisation des contributions — une composante atteignable à coût quasi nul, comme l’équité (cf. Section 6.2), n’exige aucun poids élevé ;
- *Rôle décisionnel.* Une fois les échelles ramenées à un ordre comparable, le rapport des α_i encode une politique, l’importance relative que le décideur accorde à chaque attribut.

5. Méthodologie

Trois approches sont implémentées pour résoudre le problème de NSP : (i) un **MILP exact**, (ii) une métaheuristique de **recuit simulé**, (iii) une **approche hybride ML+MILP**. Chacune est choisie pour explorer un point différent du compromis entre les quatre attributs de confiance.

5.1 Approche exacte : MILP

Garanties d’optimalité. Le solveur travaille en parallèle sur deux fronts : une suite décroissante de solutions admissibles Z^{up} (incumbents) et une suite croissante de minorants Z^{down} obtenus par relaxation continue des variables binaires. L’écart MIP $\epsilon = \frac{Z^{\text{up}} - Z^{\text{down}}}{Z^{\text{up}}}$ garantit que la solution courante est au plus ϵ -suboptimale par rapport à l’optimum global Z^* .

Calibration des poids. Le rôle décisionnel des poids α_i de la fonction objectif (cf. Section 4.5) constitue un levier de la partie *explicabilité* de l’approche MILP (cf. axe E1, Section 3.4).

Réparation après perturbation. Pour l’attribut *robustesse*, étant donnée une perturbation P1–P3 (cf. Tableau 1), le MILP reprend les contraintes (H1)–(H6) en les ajustant², et minimise une fonction objectif augmentée d’un terme de distance de Hamming à la solution nominale x^0 :

$$\min \quad Z_{\text{rep}}(x) = Z(x) + \lambda_{\text{dist}} \sum_{n \in \mathcal{N}} \sum_{d \in \mathcal{D}} \sum_{s \in \mathcal{S}'} |x_{n,d,s} - x_{n,d,s}^0|, \quad \lambda_{\text{dist}} = 5 \quad (4)$$

La distance de Hamming est linéarisée exactement, sans besoin de variables auxiliaires : si $x_{n,d,s}^0 = 0$ alors $|x_{n,d,s} - x_{n,d,s}^0| = x_{n,d,s}$; si $x_{n,d,s}^0 = 1$ alors $|x_{n,d,s} - x_{n,d,s}^0| = 1 - x_{n,d,s}$.

²Forçage de $x_{n^*, d^*, s} = 0$ pour un absent, augmentation de $\text{Req}(d^*, s^*)$ pour un pic.

5.2 Métaheuristique : Simulated Annealing

En tant qu’approche stochastique non exacte, le SA explore l’espace des solutions par mouvements aléatoires en autorisant temporairement la violation des contraintes dures — ce qui pose une question centrale pour le *respect des contraintes critiques* : contrairement au MILP, l’admissibilité finale n’est pas garantie par construction.

Représentation et énergie. La solution x est une matrice $N \times D$ d’entiers dans $\{0, 1, 2, 3\}$ codant $\{M, A, N, R\}$: une représentation dense quatre fois plus compacte que la formulation binaire du MILP (700 cellules contre 2800 variables), ce qui accélère le calcul des voisinages et des pénalités. L’énergie d’une telle solution est :

$$E(x) = Z(x) + \lambda_{\text{hard}} \cdot V(x), \quad \lambda_{\text{hard}} = 1000 \quad (5)$$

où $V(x)$ est le nombre total de violations de (H1)–(H6). Le poids élevé λ_{hard} pénalise fortement les violations sans les interdire, permettant de *viser* l’admissibilité sans la *garantir*.

Initialisation, voisinage et refroidissement. L’algorithme part d’une solution gloutonne : à chaque jour d et créneau s , les Req(d, s) infirmiers les moins chargés respectant (H3)–(H5) sont affectés, la contrainte (H6) étant laissée au SA. Puis, il utilise deux mouvements : la réaffectation d’un couple (n, d) vers un autre créneau (probabilité 0.7) et l’échange des créneaux de deux infirmiers le même jour (probabilité 0.3). Le critère de Metropolis accepte toute amélioration ($\Delta E < 0$) et, avec probabilité $\exp(-\frac{\Delta E}{T_k})$, aussi les dégradations ($\Delta E > 0$) ; la température T décroît géométriquement ($T_{k+1} = \beta T_k$, $\beta = 0.95$, $T_0 = 100$, $T_{\min} = 0.01$, $L = 700$ mouvements par palier).

Réparation. Elle suit le même principe que le MILP (cf. Eq. 4), en partant de la solution nominale avec un terme de Hamming $\lambda_{\text{dist}} \cdot \sum_{n,d,s} |x_{n,d,s} - x_{n,d,s}^0|$; les cellules forcées par la perturbation sont fixées et exclues des voisinages ($T_0 = 10$, $L = 500$).

5.3 Approche hybride : ML comme warm-start pour le MILP

L’approche hybride suit le paradigme du *warm-starting* [13, 4] : un modèle ML prédit une solution initiale $\hat{x}$ à partir des caractéristiques de l’instance. Ensuite, elle est fournie au solveur MILP comme point de départ du branch-and-bound. Le MILP raffine ensuite jusqu’au critère d’arrêt, ce qui préserve ses garanties formelles sur le respect des contraintes critiques tout en exploitant les régularités apprises pour accélérer la convergence.

Vérité terrain et descripteurs. Pour chaque triplet (n, d, s) , un vecteur ϕ de 25 descripteurs est construit à cinq niveaux de granularité (instance, infirmier, jour, créneau, triplet) du plus global au plus local. Le dataset compte 138320 triplets, modérément déséquilibrés : 25 % de $y = 1$, soit un seul créneau $s \in \mathcal{S}'$ par couple (n, d) en raison de (H1).

Modèles. Le classifieur principal est **XGBoost** [8] (300 arbres, profondeur 6, poids traités par `scale_pos_weight` pour le déséquilibre de classes) ; un **MLP** ($128 \rightarrow 64 \rightarrow 32$, BatchNorm, ReLU, Dropout, optimiseur Adam) sert de baseline. Pour les deux, la cible $y = x_{n,d,s}^*$ est apprise indépendamment pour chaque triplet.

Inférence. Sur une instance de test, l’inférence se déroule en trois étapes : (1) le ML prédit $\hat{p}(n, d, s) = P(y = 1 \mid \phi)$ pour chaque triplet ; (2) ces probabilités sont projetées sur une solution respectant (H1) — pour chaque (n, d) , le créneau $s^* = \arg \max_s \hat{p}(n, d, s)$ reçoit $\hat{x} = 1$, les autres 0 — les contraintes (H2)–(H6) étant assurées lors de la phase MILP ; (3) $\hat{x}$ est transmis à Gurobi via **Start** pour amorcer le branch-and-bound jusqu’au critère d’arrêt.

5.4 Implications pour les attributs de confiance

Les trois approches se distinguent directement sur les attributs. Le **MILP** fournit nativement, via l’écart MIP, une quantification de sa propre ϵ -suboptimalité — un atout direct pour l’*explicabilité* et le *respect des contraintes critiques*. Le **SA** en est dépourvu : l’admissibilité n’est pas garantie par construction, deux graines peuvent produire des plannings différents (question de *reproductibilité*), et l’absence de borne de qualité fragilise son *explicabilité* structurelle. L’**hybride** hérite intégralement des garanties du MILP — la suggestion ML, potentiellement inadmissible, est corrigée par le solveur final — tout en ajoutant, via l’analyse SHAP, une justification *locale* des affectations absente du MILP pur comme du SA.

6. Résultats

Cette section présente les résultats expérimentaux des trois approches de la Section 5, organisées selon les quatre attributs de confiance. L’évaluation est menée sur les 10 instances de test avec les poids $(\alpha_{eq}, \alpha_{we}, \alpha_{pref}, \alpha_{cont}) = (1, 1, 2, 0.5)$, choisis suite à l’analyse des fronts de Pareto menée en Section 6.2. Les résultats du MILP et de l’approche hybride sont reportés en moyenne $\pm$ écart-type inter-instances. Par contre, le SA étant stochastique, chaque instance est résolue avec 10 graines indépendantes ; sauf mention contraire, les valeurs SA par instance correspondent à la médiane sur les graines, agrégées ensuite en moyenne $\pm$ écart-type inter-instances.

Métrique	MILP	SA
Z	240.90 ± 11.41	275.03 ± 19.90
P_{eq}	3.28 ± 5.29 ³	0.00 ± 0.00
P_{we}	6.29 ± 4.04	7.50 ± 3.08
P_{pref}	82.01 ± 5.33	105.27 ± 4.70
P_{cont}	134.60 ± 7.93	113.55 ± 18.43
Temps	300.00 ± 0.00 s	251.27 ± 15.24 s
V	0.00 ± 0.00	0.00 ± 0.00
Gap empirique	$3.6\% \pm 1.3\%$	–

Table 4: MILP vs SA avec budget 300 s.

Le Tableau 4 fixe le cadre comparatif global. À fonction objectif strictement identique et budget égal, le MILP domine le SA sur les composantes que l’optimisation cible le plus directement — objectif global et préférences — tandis que le SA, en plus d’être plus rapide à trouver une solution, conserve un avantage localisé sur la continuité ; aucune des deux n’est donc Pareto-dominante. Le gap final moyen de 3.6% indique que le MILP épuise le budget sans certifier

³Distribution fortement asymétrique : médiane 0, IQR [0.0–8.0]. MILP atteint l’équité parfaite sur la majorité des instances, l’écart-type provenant de quelques instances difficiles sous budget contraint à 300 s.

l’optimalité : cet écart constitue une borne supérieure sur la suboptimalité, vraisemblablement pessimiste, de la solution trouvée par le MILP par rapport à Z^* .




Figure 1: Résultats de ML+MILP en fonction d’un budget entre 5 s et 60 s : cold vs warm-start.

Par ailleurs, trois constats ressortent du couplage ML+MILP (Fig. 1). D’abord, le warm-start *fiabilise* l’atteinte de l’admissibilité sous budget contraint : toutes les 10 instances disposent d’une solution admissible dès ~ 10 s, contre ~ 30 s pour le cold-start — le sursaut des courbes *cold* vers 30s reflète précisément l’entrée tardive, dans la moyenne, de l’instance la plus difficile au moment où elle devient admissible, et non une instabilité de l’algorithme. Ensuite, le gain est purement *primal* : au-delà de ~ 45 s, les trajectoires avec et sans warm-start se confondent sur l’objectif, les quatre pénalités et l’écart MIP — le warm-start accélère la convergence sans en modifier le point limite, ce qui est attendu puisqu’il ne change ni l’ensemble admissible ni la fonction objectif. Enfin, les trajectoires XGBoost et MLP sont pratiquement superposées : l’avantage relève du paradigme warm-start, non du modèle qui le fournit.

6.1 Respect des contraintes critiques

Les trois algorithmes terminent sans violer les contraintes dures : le MILP *par construction* indépendamment de la présence du modèle ML en aval, et le SA de façon *statistique* sur les 100 exécutions indépendantes (10 instances de test $\times$ 10 graines aléatoires).

Pour le MILP, l’admissibilité est une propriété formelle du modèle, sauf en cas de déclaration d’infaisabilité du problème. Pour le SA, la découverte d’une solution admissible a été facilitée par la calibration empirique de $\lambda_{\text{hard}} = 1000$: ici la pénalité est suffisamment forte pour que toutes les trajectoires stochastiques convergent vers une zone admissible. Cette garantie reste pourtant *statistique* : rien n’exclut formellement qu’une graine particulière produise une solution

inadmissible ; seule une expérimentation à plus grande échelle pourrait borner empiriquement le taux d'échec.

Cette asymétrie qualitative entre *certitude formelle* et *confiance statistique* est précisément le type d'analyse exigé pour les systèmes d'IA à haut risque par le cadre européen [14]. Pour un usage opérationnel critique, seule la certitude formelle satisfait le critère de *respect des contraintes critiques*.

6.2 Équité

Selon le Tableau 5, les JFI du MILP ne sont influencés ni par le type de modèle de ML en amont, ni par sa présence même : la solution finale étant produite par le même solveur sur la même formulation, le warm-start ne modifie ni l'ensemble admissible ni la fonction objectif, et les trajectoires de l'hybride rejoignent celles du MILP pur dès ~ 45 s (cf. Fig. 1).

Le MILP et le SA atteignent une équité comparable sur les trois dimensions, tout en respectant le budget temporel nominal : parfaite sur les charges totales, quasi-parfaite sur les weekends, et plus faible mais équivalente sur les nuits, où SA est légèrement supérieur à MILP, un écart toutefois compris dans la bande de dispersion. L'inéquité résiduelle des nuits (en deçà de 1) reste vraisemblablement structurelle — contrainte (H5) et nature entière des affectations — sans qu'un avantage net puisse être attribué à l'un ou l'autre algorithme.

Indicateur	MILP (cold)	MILP (warm)	SA
JFI _{charges}	1.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00
JFI _{nuits}	0.92 ± 0.04	0.92 ± 0.04	0.95 ± 0.03
JFI _{weekends}	0.99 ± 0.01	0.99 ± 0.01	0.98 ± 0.00

Table 5: MILP (cold et warm-start) vs SA : indicateurs d'équité.

Calibration des poids et fronts de Pareto (MILP). La calibration ne porte que sur α_{pref} et α_{cont} , seuls poids qui arbitrent une tension réelle : tout gain sur les préférences se paie en équité, tout gain en continuité se paie en préférences. L'équité, elle, s'obtient à coût quasi nul sur les autres composantes ; α_{eq} et α_{we} sont donc fixés à 1, valeur qui laisse ces pénalités atteindre leur minimum. La charge totale, divisible continûment, permet $P_{\text{eq}} = 0$ (JFI_{charges} = 1) ; le nombre entier et réduit de weekends rend en revanche WE_{target} rarement atteignable pour tous en même temps, plaçant l'optimum de P_{we} à un léger résidu (JFI_{weekends} ≈ 0.99).

Le front P_{eq} vs P_{pref} révèle un *point du coude* à $\alpha_{\text{pref}} = 2$: l'équité parfaite y est préservée ($P_{\text{eq}} = 0$) tandis que l'insatisfaction (P_{pref}) est réduite de 44% par rapport à $\alpha_{\text{pref}} = 0.1$; au-delà, les gains marginaux s'annulent et l'équité se dégrade. Le choix d' α_{cont} résulte de deux fronts complémentaires : P_{eq} vs P_{cont} *délimite* l'intervalle compatible avec l'équité parfaite ($\alpha_{\text{cont}} \in [0.5, 1.0]$), et P_{pref} vs P_{cont} y *fixe* le choix en révélant une tension structurelle (+112% sur P_{pref} pour -87% sur P_{cont} , d' $\alpha_{\text{cont}} = 0$ à 5) : on retient la borne inférieure $\alpha_{\text{cont}} = 0.5$, qui minimise le coût en préférences tout en conservant un minimum de continuité.




Figure 2: Fronts de Pareto, tracés sur l’instance de référence ($N = 25$, graine 42), extérieure au jeu de test, chaque point correspondant à une résolution MILP (budget 90 s, MIPGap = 1%).

6.3 Robustesse

La robustesse est évaluée sur la même instance de référence que Fig. 2 sur les trois perturbations P1–P3 (Section 3.3), chacune soumise à 10 tirages aléatoires. Le Tableau 6 révèle trois asymétries structurelles entre le MILP et le SA :

- **Asymétrie de qualité médiane.** En *médiane*, le SA est compétitif avec le MILP sur P1 et P3 ; le MILP ne domine nettement que sur P2. C’est la *queue* de la distribution du SA qui dégrade ses moyennes : le SA produit des réparations souvent correctes, mais occasionnellement très coûteuses ;
- **Asymétrie d’écart-type.** La dispersion du SA est tellement plus élevée que la distance de Hamming induite par P1 sur les 10 tirages présente une distribution bimodale avec une queue droite très étendue en raison d’une valeur aberrante. Cela pose un problème de *prédictibilité* opérationnelle : un manager recevant une solution du SA ne peut pas anticiper le nombre de réaffectations à communiquer à son équipe. Cette imprévisibilité viole le principe de *stabilité des sorties* attendu d’un système d’IA de confiance ;
- **Asymétrie de temps.** Le SA est extrêmement plus lent que le MILP en réparation (~ 157 s contre $\sim 0.3\text{--}0.5$ s) pour deux raisons : (1) le SA redémarre le recuit entier même pour une réparation simple, tandis que le MILP se limite à trouver la déviation minimale pour retourner à x^0 ; (2) l’ampleur limitée des modifications et la distance à la frontière d’admissibilité ont permis au MILP d’atteindre un temps de résolution très rapide. Cet écart est décisif pour l’usage opérationnel : pour une réaction à un événement imprévu, seul le MILP est compatible avec les contraintes temporelles d’un service hospitalier réel.

L’hybride présente des métriques du même ordre que le MILP pur, les écarts restant compris dans la dispersion des 10 tirages, lesquels dépendent en outre, pour P1 et P3, de la solution nominale propre à chaque approche. La réparation étant assurée par le même solveur MILP, la robustesse opérationnelle du pipeline hybride hérite directement de celle du MILP — temps de réparation $\lesssim 0.6$ s et garantie d’admissibilité.

Aucun scénario testé n’a conduit à une infaisabilité, ce qui indique que l’instance ici considérée dispose d’une marge réglementaire suffisante pour absorber les perturbations considérées. La distance de Hamming croît cependant significativement avec l’intensité de la perturbation ($5.5\times$ entre P1 et P3 pour le MILP), suggérant que le *coût organisationnel* (nombre de réaffectations à communiquer) est un indicateur plus sensible que la seule valeur de l’objectif.

Scénario	Algorithme	Hamming	ΔZ	Temps
P1 (absence individuelle)	MILP	4.0 ± 1.9	$+1.3\% \pm 0.7\%$	0.24 ± 0.02 s
	SA	$10.1 \pm 14.6^\dagger$	$+2.6\% \pm 2.2\%$	156.8 ± 0.6 s
	XGB+MILP	3.8 ± 0.6	$+1.2\% \pm 0.5\%$	0.28 ± 0.07 s
	MLP+MILP	4.2 ± 0.6	$+1.2\% \pm 0.5\%$	0.38 ± 0.09 s
P2 (pic de demande)	MILP	8.0 ± 2.1	$+3.7\% \pm 1.3\%$	0.53 ± 0.31 s
	SA	$23.8 \pm 10.1^\dagger$	$+6.4\% \pm 2.5\%$	156.8 ± 1.0 s
	XGB+MILP	6.2 ± 1.5	$+3.3\% \pm 1.2\%$	0.37 ± 0.10 s
	MLP+MILP	6.6 ± 2.1	$+3.4\% \pm 0.8\%$	0.43 ± 0.29 s
P3 (épidémie)	MILP	22.0 ± 6.7	$+5.7\% \pm 1.4\%$	0.36 ± 0.13 s
	SA	$20.6 \pm 11.4^\dagger$	$+6.5\% \pm 3.1\%$	156.7 ± 0.5 s
	XGB+MILP	19.8 ± 3.9	$+5.2\% \pm 1.1\%$	0.41 ± 0.20 s
	MLP+MILP	19.0 ± 5.5	$+5.2\% \pm 1.1\%$	0.56 ± 0.28 s

Scénario	SA	Hamming (médiane)	IQR (Q1-Q3)	Max Hamming
P1		4.5	[0 – 12]	45
P2		26	[25 – 27.75]	40
P3		19	[14 – 26.25]	45

Table 6: MILP vs SA vs ML+MILP : réaction aux perturbations. Aucune exécution (30/30 par algorithme) ne se termine avec des violations résiduelles.

[†]Les résultats du coût de réparation du SA sont trop instables, donc ils sont reportés aussi sous forme de médiane et IQR.

6.4 Explicabilité

(E1) Fronts de Pareto. La calibration des poids (Section 6.2) constitue le premier niveau d’explicabilité, *global* : les fronts bi-objectifs cartographient les compromis réalisables entre équité, préférences et continuité, rendant chaque arbitrage explicite et auditable. Là où un poids choisi *a priori* resterait opaque, le tracé des fronts permet à un gestionnaire de situer la configuration retenue (1, 1, 2, 0.5) sur une courbe de compromis et d’en lire le coût : la politique encodée n’est pas postulée mais justifiée graphiquement, y compris pour un décideur non spécialiste de l’optimisation.

(E2) Contraintes déterminantes (saturation primale). L’analyse des contraintes actives sur la solution MILP fournit une justification structurelle des affectations non préférées, fondée sur la saturation des contraintes primales. La totalité des 20 affectations les moins préférées — toutes au-dessus de 0.33, le MILP n’imposant jamais de créneau fortement indésirable — correspondent à un créneau dont la couverture est strictement au minimum requis : la contrainte de couverture (H2) est *déterminante*, le solveur ne dégradant une préférence que lorsque la

couverture l'exige. Dans 40 % des cas, s'y ajoute la saturation du quota de nuits (H5), qui restreint davantage les alternatives de l'infirmier concerné. La saturation des weekends libres (H6) n'est en revanche pas discriminante : la solution alloue à *chaque* infirmier exactement le minimum réglementaire ($WE_{\min} = 2$ pour les 25 infirmiers), régularité structurelle globale distincte de la justification locale (Tableau 7). Cette justification n'est disponible que pour les approches atteignant la borne de suboptimalité certifiée (MILP et, par héritage, l'hybride) : pour le SA, dont les solutions sont des minima locaux, une affectation non préférée ne peut être attribuée de manière univoque à une contrainte active plutôt qu'à la sous-optimalité.

Contrainte	Saturation	Rôle
H2 (couverture minimale)	20/20 affectations	Déterminante
H5 (quota de nuits)	8/20 (40 %)	Co-déterminante
H6 (weekends libres)	25/25 infirmiers	Non discriminante

Table 7: Saturation des contraintes primales sur les 20 affectations les moins préférées de l'instance MILP de référence. Une contrainte n'explique une affectation que si sa saturation lui est spécifique (H2, H5) ; H6, saturée uniformément, relève d'une régularité globale.


(E3) Importance des descripteurs à travers SHAP (XGB). Quatre descripteurs (Tableau 8), dont trois indiquent une préférence (P) et un est structurel (S), surpassent nettement les autres et expliquent $\sim 74\%$ de l'importance totale :

Feature	Description
<code>nds_n_pref_minus_avg</code> (P)	Écart entre la préférence de l'infirmier pour ce créneau et sa préférence moyenne sur tout l'horizon : $\text{pref}(n, d, s) - \overline{\text{pref}}_n \forall d, s$. Il mesure l'attrait <i>relatif au standard personnel</i> de l'infirmier.
<code>nds_pref</code> (P)	$\text{pref}(n, d, s)$.
<code>nds_req_ratio</code> (S)	Taux de demande du créneau : nombre d'infirmiers requis rapporté à l'effectif total, $\frac{1}{N}\text{Req}(d, s)$. Il encode la rareté (structurelle) du poste.
<code>nds_pref_relative</code> (P)	Écart entre la préférence pour ce créneau et la moyenne des trois créneaux du <i>même jour</i> : $\text{pref}(n, d, s) - \overline{\text{pref}}_{n,d} \forall s$. Il mesure l'attrait relatif aux alternatives du jour.


Table 8: Les quatre descripteurs les plus influents de XGBoost.

XGBoost n'exploite pas l'identité du créneau (`s_is_M/A/N`, SHAP moyen < 0.05) et du weekend (`d_is_weekend`, SHAP moyen ≈ 0.003) : au-delà de leur SHAP faible, leur corrélation avec les quatre descripteurs du Tableau 8 l'est aussi (max 0.26). Donc, les identités du créneau et du weekend portent des informations non redondantes, mais le modèle choisit de se concentrer ailleurs. Au niveau architectural, XGBoost capture la dimension des préférences des infirmiers et délègue la dimension de la fiabilité (H3, H5, H6) au solveur MILP en aval.

Selon les plots de dépendance, les quatre descripteurs les plus influents ont tous une relation monotone croissante, indice d'un comportement prévisible. En particulier, `nds_pref` présente un effet seuil à environ 0.2 : en dessous de cette valeur, la préférence contribue toujours négativement à la prédiction (SHAP < 0), poussant le modèle vers le non-affecté ($y = 0$). Aussi, `nds_req_ratio`



(a) Les descripteurs les plus influents.



(b) Dépendance SHAP des descripteurs du Tableau 8.

Figure 3: Analyse SHAP de XGB lors de la solution générée par la graine 42.

est nettement influencé par la préférence d’un infirmier, car son graphe montre deux groupes distincts : celui des créneaux de $\mathcal{S}_{\text{work}}$ à gauche, où **nds_pref** est positivement corrélé avec la valeur SHAP, donc une préférence plus forte implique une affectation plus probable ; et le groupe à droite des repos, caractérisé par une valeur SHAP toujours positive.⁴

6.5 Limite de la formalisation

L’inspection des plannings produits par le MILP (cf. Fig. 4) révèle des blocs consécutifs de nuits, conséquence de P_{cont} , qui récompense uniformément la régularité de tous les créneaux, alors que l’enchaînement de nuits est délétère du point de vue de la fatigue [22]. Une expérience de contrôle ajoutant à l’objectif une pénalité de dispersion des nuits⁵ $P_{\text{night_consec}} = \sum_{n=1}^N \sum_{d=1}^{D-1} z_{n,d}$ ($\alpha_{\text{night_consec}} = 1$) supprime intégralement ces enchaînements sans dégrader l’équité et en améliorant même légèrement les préférences ($P_{\text{pref}} : 82.9 \rightarrow 79.2$) : la seule métrique à se détériorer est P_{cont} ($130 \rightarrow 179$), précisément la pénalité dont l’application uniforme aux nuits est en cause.

Une seconde limite, déclarée dès la formalisation (Section 4.3), concerne le repos entre créneaux : la borne légale de 11 h (art. L3131-1 [34]) exigerait, dans la partition 3×8 retenue, d’exclure également $A \rightarrow M$ et $N \rightarrow A$. Une expérience de contrôle sur l’instance de référence indique que cette conformité stricte reste admissible, pour un surcoût sur l’incumbent à 300 s inférieur au gap résiduel (+0.4 %, équité préservée) ; son effet principal est structurel — après une nuit, seule une nuit ou un repos restent possibles — et renforce précisément les blocs de nuits mis en cause ci-dessus : exigence réglementaire et exigence clinique peuvent ainsi entrer en tension au sein même des contraintes dures.

⁴La distinction des clusters par créneau de $\mathcal{S}'$ est justifiée par deux choix d’implémentation du code :

- **nds_req_ratio** est calculé comme la fraction des infirmiers requises dans le cas M/A/N ($\text{req_ratio} = \text{Req}[(d, s)] / N$), sinon comme fraction attendue à repos ($\text{req_ratio} = 1 - \text{daily_demand}[d] / N$). Les deux formules créent les deux clusters par construction : un créneau N peut générer une fraction petite (peu d’infirmiers pour une nuit, ex. 3 nuits sur 25 ≈ 0.12), un repos une fraction plus grande (1 - fraction des gens qui travaillent $\approx 0.5\text{--}0.65$) ;

- Quant à **nds_pref**, par convention $\text{pref}(n, d, R) = 0.5$, exactement ce que témoigne le cluster à droite.

⁵ $z_{n,d} = x_{n,d,N} \cdot x_{n,d+1,N}$, linéarisée par $z_{n,d} \geq x_{n,d,N} + x_{n,d+1,N} - 1 \quad \forall n \in \mathcal{N}, d \in \mathcal{D} \setminus \{D\}$

	L1	Ma2	Me3	J4	V5	S6	D7	L8	Ma9	Me10	J11	V12	S13	D14	L15	Ma16	Me17	J18	V19	S20	D21	L22	Ma23	Me24	J25	V26	S27	D28
Inf.0	R	R	R	M	M	R	R	R	R	N	A	A	A	A	R	N	N	N	R	M	M	R	R	R	R	M	R	R
Inf.1	R	R	R	N	R	M	R	R	R	R	R	R	N	N	N	R	R	M	M	R	R	M	R	M	M	M	M	M
Inf.2	M	M	R	R	N	R	R	R	R	R	N	N	R	R	R	R	M	R	A	A	R	R	R	A	A	A	A	A
Inf.3	A	R	M	M	R	R	R	R	R	R	M	M	M	A	R	R	R	R	A	A	R	N	N	N	N	N	R	R
Inf.4	R	R	A	A	R	M	R	R	R	R	A	A	A	A	A	R	R	N	N	R	N	R	R	R	R	R	R	R
Inf.5	N	N	R	R	A	N	N	R	R	R	R	R	R	R	R	A	A	A	A	A	R	A	A	A	R	R	R	R
Inf.6	N	N	R	N	R	R	R	R	R	M	M	M	M	M	R	R	R	M	R	R	R	R	A	A	A	R	R	M
Inf.7	R	R	M	M	M	R	A	A	A	R	R	R	R	R	R	R	R	R	R	R	R	N	N	R	R	N	N	A
Inf.8	A	A	A	A	R	R	R	N	N	R	R	R	M	M	R	R	R	R	R	R	A	A	A	A	M	R	R	R
Inf.9	R	A	A	A	A	A	R	R	R	R	M	R	R	N	N	A	A	R	R	R	R	R	R	R	R	R	N	N
Inf.10	M	M	M	R	R	M	M	M	M	M	R	R	R	R	A	A	R	N	N	R	N	R	R	R	R	R	R	R
Inf.11	R	M	N	N	N	R	A	A	A	A	A	R	M	M	M	M	R	R	R	R	R	R	R	R	R	R	R	R
Inf.12	R	R	M	R	R	R	R	A	A	A	A	R	R	R	R	R	N	N	N	N	R	R	R	M	M	M	M	M
Inf.13	R	R	R	R	R	R	R	R	M	M	M	A	R	M	M	R	N	R	R	R	R	A	A	R	A	A	M	M

Figure 4: Affectation proposée par le MILP : mise en évidence de blocs de nuits consécutifs attribués à quelques infirmiers.

Au-delà de ces cas particuliers, ce constat illustre un point central pour l’IA de confiance : une solution *optimale* au sens d’une fonction objectif incomplète peut être cliniquement sous-optimale sur une dimension non modélisée — l’optimalité n’est garantie que relativement à la formalisation retenue.

7. Conclusion

Ce travail a proposé une formalisation du NSP dérivée des attributs de confiance — chaque contrainte et chaque pénalité étant rattachées à un attribut — et une évaluation systématique de trois approches (MILP exact, recuit simulé, hybride ML+MILP) selon ces mêmes attributs, sur un jeu de dix instances de test.

Sur le **respect des contraintes critiques**, l’asymétrie est qualitative : le MILP garantit l’admissibilité par construction, tandis que le SA, bien qu’admissible sur l’intégralité de ses cent exécutions, ne l’offre que de façon statistique — distinction décisive pour un système à haut risque, où seule la garantie formelle satisfait le critère. Sur l’**équité**, les deux approches sont comparables. Sur la **robustesse**, le MILP répare les perturbations rapidement et de façon prévisible sur l’instance étudiée, là où le SA est lent et fortement dispersé ; l’hybride hérite intégralement du comportement du MILP. Sur l’**explicabilité**, le MILP dispose nativement d’outils d’interprétation (écart MIP comme mesure d’incertitude, fronts de Pareto) que le SA n’offre pas, l’hybride y ajoutant une analyse SHAP des descripteurs. Globalement, le MILP domine en ce qui concerne l’objectif et les préférences, le SA conserve un avantage localisé sur la continuité, et aucune approche n’est Pareto-dominante.

L’apport de l’hybride doit être qualifié honnêtement : le warm-start fiabilise l’atteinte d’une première solution admissible sous budget contraint, mais n’améliore pas la qualité de la solution finale. Son intérêt est donc primal — vitesse et faisabilité — plutôt que qualitatif.

Plusieurs *limites* circonscrivent ces conclusions. Les poids de la fonction objectif ont été calibrés sur le MILP puis appliqués aux trois approches pour comparabilité, sans calibration spécifique à chaque algorithme. De même, le protocole de robustesse repose sur une instance unique avec dix tirages par scénario : les asymétries observées entre MILP et SA — trois ordres de grandeur sur le temps, dispersion — sont de nature structurelle, mais leur amplitude reste à confirmer sur

l'ensemble du jeu de test. Surtout, les deux expériences de contrôle de la Section 6.5 illustrent que les garanties ne valent que relativement à la formalisation retenue : une solution optimale au sens d'un objectif incomplet peut rester cliniquement sous-optimale sur une dimension non modélisée, et la conformité garantie porte sur les contraintes retenues (repos de 8 h) plutôt que sur la borne légale de 11 h. Enfin, le régime des grandes instances, où le passage à l'échelle du SA pourrait devenir déterminant, n'a pas été exploré : pour les tailles étudiées, le MILP reste plus performant tout en garantissant l'admissibilité de la solution.

Ces limites dessinent les *perspectives* : évaluation sur des instances de plus grande taille pour situer le compromis exact/métaheuristique au-delà du régime testé, désagrégation de la pénalité de continuité par type de créneau, calibration spécifique des poids à chaque algorithme, introduction d'autres contraintes cliniques dans la formalisation et intégration proactive de l'incertitude dans le modèle, en complément de l'approche réactive adoptée ici.

Références

- [1] Henrik Abgaryan, Ararat Harutyunyan, and Tristan Cazenave. “LLMs Can Schedule”. In: *arXiv preprint arXiv:2408.06993* (2024). DOI: [10.48550/arXiv.2408.06993](https://doi.org/10.48550/arXiv.2408.06993).
- [2] Linda H. Aiken et al. “Hospital Nurse Staffing and Patient Mortality, Nurse Burnout, and Job Dissatisfaction”. In: *JAMA* 288.16 (2002), pp. 1987–1993. DOI: [10.1001/jama.288.16.1987](https://doi.org/10.1001/jama.288.16.1987).
- [3] Cristian Belfiore. “An Effective Matheuristic Approach to Solve Nurse Rostering Problem”. In: *Beyond Frontiers of Operations Research: Emerging Technologies and Innovative Optimization Paradigms*. Vol. 14. AIRO Springer Series. Springer, 2025, pp. 99–109. DOI: [10.1007/978-3-031-85894-9_8](https://doi.org/10.1007/978-3-031-85894-9_8).
- [4] Yoshua Bengio, Andrea Lodi, and Antoine Prouvost. “Machine Learning for Combinatorial Optimization: A Methodological Tour d’Horizon”. In: *European Journal of Operational Research* 290.2 (2021), pp. 405–421. DOI: [10.1016/j.ejor.2020.07.063](https://doi.org/10.1016/j.ejor.2020.07.063).
- [5] Edmund K. Burke et al. “The State of the Art of Nurse Rostering”. In: *Journal of Scheduling* 7 (2004), pp. 441–499. DOI: [10.1023/B:JOSH.0000046076.75950.0b](https://doi.org/10.1023/B:JOSH.0000046076.75950.0b).
- [6] Sara Ceschia et al. “Solving a Real-World Nurse Rostering Problem by Simulated Annealing”. In: *Operations Research for Health Care* 36 (2023), p. 100379. DOI: [10.1016/j.orhc.2023.100379](https://doi.org/10.1016/j.orhc.2023.100379).
- [7] Sara Ceschia et al. “The Second International Nurse Rostering Competition”. In: *Annals of Operations Research* 274 (2019), pp. 171–186. DOI: [10.1007/s10479-018-2816-0](https://doi.org/10.1007/s10479-018-2816-0).
- [8] Tianqi Chen and Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. In: KDD ’16. Association for Computing Machinery, 2016, pp. 785–794. ISBN: 9781450342322. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [9] Ziyi Chen, Patrick De Causmaecker, and Yajie Dou. “A Combined Mixed Integer Programming and Deep Neural Network-Assisted Heuristics Algorithm for the Nurse Rostering Problem”. In: *Applied Soft Computing* 136 (2023). DOI: [10.1016/j.asoc.2022.109919](https://doi.org/10.1016/j.asoc.2022.109919).
- [10] Ziyi Chen, Yajie Dou, and Patrick De Causmaecker. “Neural Networked-Assisted Method for the Nurse Rostering Problem”. In: *Computers & Industrial Engineering* 171 (2022), p. 108430. DOI: [10.1016/j.cie.2022.108430](https://doi.org/10.1016/j.cie.2022.108430).
- [11] Tim B. Cooper and Jeffrey H. Kingston. “The complexity of timetable construction problems”. In: *Practice and Theory of Automated Timetabling* 1153 (1996), pp. 281–295. DOI: [10.1007/3-540-61794-9_66](https://doi.org/10.1007/3-540-61794-9_66).
- [12] Tim Curtois. *Employee Shift Scheduling Benchmark Data Sets*. 2014. URL: <http://www.schedulingbenchmarks.org>.
- [13] Jian-Ya Ding et al. “Accelerating Primal Solution Findings for Mixed Integer Programs Based on Solution Prediction”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 34. 2. 2020. DOI: [10.1609/aaai.v34i02.5503](https://doi.org/10.1609/aaai.v34i02.5503).
- [14] European Parliament and Council. *Regulation (EU) 2024/1689 — The AI Act*. Official Journal of the European Union. 2024. URL: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>.

- [15] Celia A. Glass and Roger A. Knight. “The Nurse Rostering Problem: A Critical Appraisal of the Problem Structure”. In: *European Journal of Operational Research* 202.2 (2010), pp. 379–389. DOI: [10.1016/j.ejor.2009.05.046](https://doi.org/10.1016/j.ejor.2009.05.046).
- [16] Jia Guo and Jonathan F. Bard. “A Column Generation-Based Algorithm for Midterm Nurse Scheduling with Specialized Constraints, Preference Considerations, and Overtime”. In: *Computers & Operations Research* 138 (2022), p. 105597. DOI: [10.1016/j.cor.2021.105597](https://doi.org/10.1016/j.cor.2021.105597).
- [17] Stefaan Haspeslagh et al. “The First International Nurse Rostering Competition 2010”. In: *Annals of Operations Research* 218 (2014), pp. 221–236. DOI: [10.1007/s10479-012-1062-0](https://doi.org/10.1007/s10479-012-1062-0).
- [18] Mohammad Reza Hassani and Javad Behnamian. “A Scenario-Based Robust Optimization with a Pessimistic Approach for Nurse Rostering Problem”. In: *Journal of Combinatorial Optimization* 41 (2021), pp. 143–169. DOI: [10.1007/s10878-020-00667-0](https://doi.org/10.1007/s10878-020-00667-0).
- [19] High-Level Expert Group on AI. *Ethics Guidelines for Trustworthy AI*. European Commission. 2019. URL: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>.
- [20] Rajendra K. Jain, Dah-Ming W. Chiu, and William R. Hawe. *A Quantitative Measure of Fairness and Discrimination for Resource Allocation in Shared Computer Systems*. Tech. rep. TR-301. Digital Equipment Corporation, 1984.
- [21] Elias Boutros Khalil et al. “Learning to Branch in Mixed Integer Programming”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 30. 1. 2016. DOI: [10.1609/aaai.v30i1.10080](https://doi.org/10.1609/aaai.v30i1.10080).
- [22] Kjartan Kastet Klyve, Ilankaikone Senthooran, and Mark Wallace. “Nurse Rostering with Fatigue Modelling: Incorporating a Validated Sleep Model with Biological Variations in Nurse Rostering”. In: *Health Care Management Science* 26.1 (2023), pp. 21–45. DOI: [10.1007/s10729-022-09613-4](https://doi.org/10.1007/s10729-022-09613-4).
- [23] Harsha Koduri. “NurseSchedRL: Attention-Guided Reinforcement Learning for Nurse-Patient Assignment”. In: *arXiv preprint arXiv:2509.18125* (2025).
- [24] Wouter Kool, Herke van Hoof, and Max Welling. “Attention, Learn to Solve Routing Problems!” In: *International Conference on Learning Representations (ICLR)*. 2019. DOI: [10.48550/arXiv.1803.08475](https://doi.org/10.48550/arXiv.1803.08475).
- [25] Antoine Legrain and Jérémy Omer. “A Dedicated Pricing Algorithm to Solve a Large Family of Nurse Scheduling Problems with Branch-and-Price”. In: *INFORMS Journal on Computing* (2024). DOI: [10.1287/ijoc.2023.0019](https://doi.org/10.1287/ijoc.2023.0019).
- [26] Scott M. Lundberg and Su-In Lee. “A Unified Approach to Interpreting Model Predictions”. In: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. 2017, pp. 4765–4774.
- [27] Saman Malekian et al. “New Nurse Scheduling Problem Considering Burnout Factor and Undesirable Shifts under COVID-19 (A real case study)”. In: *Journal of Industrial and Systems Engineering* 15.1 (2023), pp. 280–305.
- [28] Aniek F. Markus, Jan A. Kors, and Peter R. Rijnbeek. “The Role of Explainability in Creating Trustworthy Artificial Intelligence for Health Care: A Comprehensive Survey of the Terminology, Design Choices, and Evaluation Strategies”. In: *Journal of Biomedical Informatics* 113 (2021), p. 103655. DOI: [10.1016/j.jbi.2020.103655](https://doi.org/10.1016/j.jbi.2020.103655).

- [29] Chong Man Ngoo et al. “A Survey of the Nurse Rostering Solution Methodologies: The State-of-the-Art and Emerging Trends”. In: *IEEE Access* 10 (2022), pp. 56504–56524. DOI: [10.1109/ACCESS.2022.3177280](https://doi.org/10.1109/ACCESS.2022.3177280).
- [30] Ayoub Ouhadi, Zakaria Yahouni, and Maria Di Mascolo. “Integrating Machine Learning and Operations Research Methods for Scheduling Problems: A Bibliometric Analysis and Literature Review”. In: *IFAC-PapersOnLine* 58.19 (2024). DOI: [10.1016/j.ifacol.2024.09.155](https://doi.org/10.1016/j.ifacol.2024.09.155).
- [31] Erfan Rahimian, Kerem Akartunalı, and John Levine. “A Hybrid Integer Programming and Variable Neighbourhood Search Algorithm to Solve Nurse Rostering Problems”. In: *European Journal of Operational Research* 258.2 (2017), pp. 411–423. DOI: [10.1016/j.ejor.2016.09.030](https://doi.org/10.1016/j.ejor.2016.09.030).
- [32] Fabienne Josefine Renggli et al. “Integrating Nurse Preferences Into AI-Based Scheduling Systems: Qualitative Study”. In: *JMIR Formative Research* 9 (2025), e67747. DOI: [10.2196/67747](https://doi.org/10.2196/67747).
- [33] République française. *Code du travail, article L3121-20*. Légifrance. Durée maximale hebdomadaire de travail de 48 heures ; version en vigueur depuis le 10 août 2016. 2016. URL: https://www.legifrance.gouv.fr/codes/article_lc/LEGIARTI000033020414.
- [34] République française. *Code du travail, article L3131-1*. Légifrance. Repos quotidien minimal de 11 heures consécutives ; version en vigueur depuis le 10 août 2016. 2016. URL: https://www.legifrance.gouv.fr/codes/article_lc/LEGIARTI000033020918.
- [35] Pavinee Rerkjirattikal et al. “A Goal Programming Approach to Nurse Scheduling with Individual Preference Satisfaction”. In: *Mathematical Problems in Engineering* 2020.1 (2020), p. 2379091. DOI: [10.1155/2020/2379091](https://doi.org/10.1155/2020/2379091).
- [36] Haroldo G. Santos et al. “Integer Programming Techniques for the Nurse Rostering Problem”. In: *Annals of Operations Research* 239.1 (2016), pp. 225–251. DOI: [10.1007/s10479-014-1594-6](https://doi.org/10.1007/s10479-014-1594-6).
- [37] Nagisa Sugishita, Andreas Grothey, and Ken McKinnon. “Use of Machine Learning Models to Warmstart Column Generation for Unit Commitment”. In: *INFORMS Journal on Computing* 36.4 (2024), pp. 1129–1146. DOI: [10.1287/ijoc.2022.0140](https://doi.org/10.1287/ijoc.2022.0140).
- [38] Jorne Van den Bergh et al. “Personnel Scheduling: A Literature Review”. In: *European Journal of Operational Research* 226.3 (2013), pp. 367–385. DOI: [10.1016/j.ejor.2012.11.029](https://doi.org/10.1016/j.ejor.2012.11.029).
- [39] Michael Warner and Juan Prawda. “A Mathematical Programming Model for Scheduling Nursing Personnel in a Hospital”. In: *Management Science* 19.4 (1972), pp. 411–422. DOI: [10.1287/mnsc.19.4.411](https://doi.org/10.1287/mnsc.19.4.411).
- [40] Chang Ho Yoon, Robert Torrance, and Naomi Scheinerman. “Machine learning in medicine: should the pursuit of enhanced interpretability be abandoned?” In: *Journal of Medical Ethics* 48.9 (2022), pp. 581–585. DOI: [10.1136/medethics-2020-107102](https://doi.org/10.1136/medethics-2020-107102).
- [41] Si Zhang, Paul Mingzheng Tang, and Hoong Chuin Lau. “A Nurse Staffing and Scheduling Problem with Bounded Flexibility and Demand Uncertainty”. In: *arXiv preprint arXiv:2505.22124* (2025). DOI: [10.48550/arXiv.2505.22124](https://doi.org/10.48550/arXiv.2505.22124).